Integrazione di ragionamento simbolico e apprendimento automatico per la valutazione del rischio di malattie delle colture.

Componenti:

Emanuele Misceo, matricola 798651, e.misceo1@studenti.uniba.it

Camilla Vaira, matricola 800280, c.vaira1@studenti.uniba.it

A.A. 2025/26

Indice

1 Introduzione **2**

2 Dataset e Data Collection **3**

3 Knowledge Base in Prolog **5**

3.1 Ruolo della Knowledge Base 5

3.2 Rappresentazione della conoscenza in Prolog 6

3.3 Applicazione delle regole al dataset 8

3.4 Analisi strutturale quantitativa della KB 9

3.5 Limiti e valutazioni conclusive 9

4 Knowledge Graph **10**

4.1 Rappresentazione in Triple e Classi di Nodi 10

4.2 Definizione delle Relazioni 10

4.3 Rappresentazioni Grafiche e Analisi Visiva 11

5 Apprendimento Supervisionato **13**

5.1 Preprocessing 13

5.2 Modelling e Scelte Tecniche 13

5.3 Analisi del Processo di Addestramento 15

5.4 Analisi sul Test Set e Curve di Apprendimento 16

5.5 Analisi degli Errori 19

6 Prototipo di utilizzo **22**

7 Conclusioni **23**

1 Introduzione

Nell'agricoltura di precisione, la valutazione del rischio di patologie vegetali ha un ruolo fondamentale. Le malattie delle colture sono fortemente influenzate dalle condizioni ambientali (come temperatura, umidità e caratteristiche del suolo) e possono causare ingenti perdite economiche se non anticipate correttamente.

L'obiettivo di questo progetto è sviluppare un Knowledge-Based System (KBS) ibrido, capace di valutare il rischio di insorgenza patogena integrando ragionamento simbolico e apprendimento automatico. A differenza dei tradizionali approcci basati esclusivamente sui dati, il sistema proposto sfrutta la conoscenza di dominio esplicita per arricchire il processo decisionale.

Il sistema mira a individuare, secondo le regole formalizzate nella Knowledge Base, condizioni compatibili con il rischio di specifici patogeni, considerando la tipologia di coltura e i relativi parametri ambientali, meteorologici e del suolo.

La prima componente del sistema è una Knowledge Base (KB) in Prolog, che mediante le caratteristiche della coltura e i parametri ambientali e del suolo, restituisce gli eventuali patogeni compatibili. Questi risultati vengono utilizzati per costruire una variabile binaria, che distingue i campioni per i quali la KB deduce un rischio compatibile con uno o più patogeni, da quelli non a rischio.

La seconda componente è un Knowledge Graph che rappresenta le colture, i patogeni dedotti dalla KB e i valori ambientali medi associati alle singole colture.

La terza componente comprende tre classificatori supervisionati: Decision Tree, Random Forest e K-Nearest Neighbors. Il target è binario, derivato dalla KB, mentre le feature numeriche vengono perturbate artificialmente per simulare possibili imprecisioni nelle misurazioni.

La valutazione confronta i tre modelli mediante Nested Cross-Validation. Le prestazioni vengono analizzate attraverso più metriche, considerando sia i risultati medi sia la loro variabilità tra le diverse partizioni dei dati.

2 Dataset e Data Collection

Il dataset di partenza è il Crop Recommendation Dataset [1] che raccoglie rilevazioni ambientali, meteorologiche e parametri del suolo, associati a diverse tipologie di colture. Queste informazioni costituiscono i dati di ingresso utilizzati per interrogare la Knowledge Base e, successivamente, per addestrare i modelli di classificazione.

L'analisi esplorativa dei dati (Data Understanding) esamina la struttura del dataset, le tipologie di variabili, gli eventuali valori mancanti e le distribuzioni delle feature numeriche e categoriche. Sono state inoltre calcolate statistiche descrittive per le variabili numeriche e analizzata la distribuzione del target binario generato dalla KB.

Inoltre questa fase è stata fondamentale per orientare le successive scelte di preprocessing e modellazione. Dall'analisi delle variabili continue (Azoto, Fosforo, Potassio, Temperatura, Umidità, pH e Precipitazioni) si evince che i dati presentano scale di grandezza eterogenee e distribuzioni variegate (Fig. 1). Questa eterogeneità dei dati ha reso indispensabile l'implementazione di uno step di standardizzazione nella pipeline di pre-elaborazione per evitare che le variabili con maggiore dimensione dominassero i modelli basati sulla distanza.

Variabile	**Count**	**Mean**	**Std**	**Min**	**25%**	**50%**	**75%**	**Max**
N	2200.0	50.55	36.92	0.00	21.00	37.00	84.25	140.00
P	2200.0	53.36	32.99	5.00	28.00	51.00	68.00	145.00
K	2200.0	48.15	50.65	5.00	20.00	32.00	49.00	205.00
temperature	2200.0	25.62	5.06	8.83	22.77	25.60	28.56	43.68
humidity	2200.0	71.48	22.26	14.26	60.26	80.47	89.95	99.98
ph	2200.0	6.47	0.77	3.50	5.97	6.43	6.92	9.94
rainfall	2200.0	103.46	54.96	20.21	64.55	94.87	124.27	298.56
Target_Rischio	2200.0	0.03	0.18	0.00	0.00	0.00	0.00	1.00

Tabella 1: Statistiche descrittive delle variabili numeriche del dataset.

Per facilitare l'analisi descrittiva delle colture, è stata introdotta la variabile Categoria_Crop, che associa le colture a categorie più ampie, con una forte prevalenza della classe dei "Legumi", seguita da "Vite e Cucurbitacee" e "Fruttiferi Tropicali" (Fig. 2). Questa variabile viene utilizzata esclusivamente per l'analisi esplorativa e per confrontare la distribuzione dei campioni tra i gruppi individuati. La classificazione botanica utilizzata dalla Knowledge Base è rappresentata separatamente mediante fatti e regole Prolog: Categoria Crop non viene passata direttamente alla KB. La variabile viene inoltre esclusa dalla fase di apprendimento automatico, nella quale si mantiene il nome originale della coltura.

L'elemento più critico emerso dall'esplorazione è la distribuzione della variabile target binaria (rischio di malattia). Il dataset risulta fortemente sbilanciato, con un'ampia maggioranza di campioni appartenenti alla classe negativa (Nessun rischio, target = 0) rispetto a quelli a rischio (target = 1). Questo sbilanciamento giustifica la necessità di adottare in fase di addestramento tecniche specifiche sia per quanto riguarda i modelli sia per quanto riguarda la scelta delle metriche di valutazione. È necessario precisare che il target non è una variabile originariamente presente nel dataset, ma viene costruito dalle inferenze di Prolog.

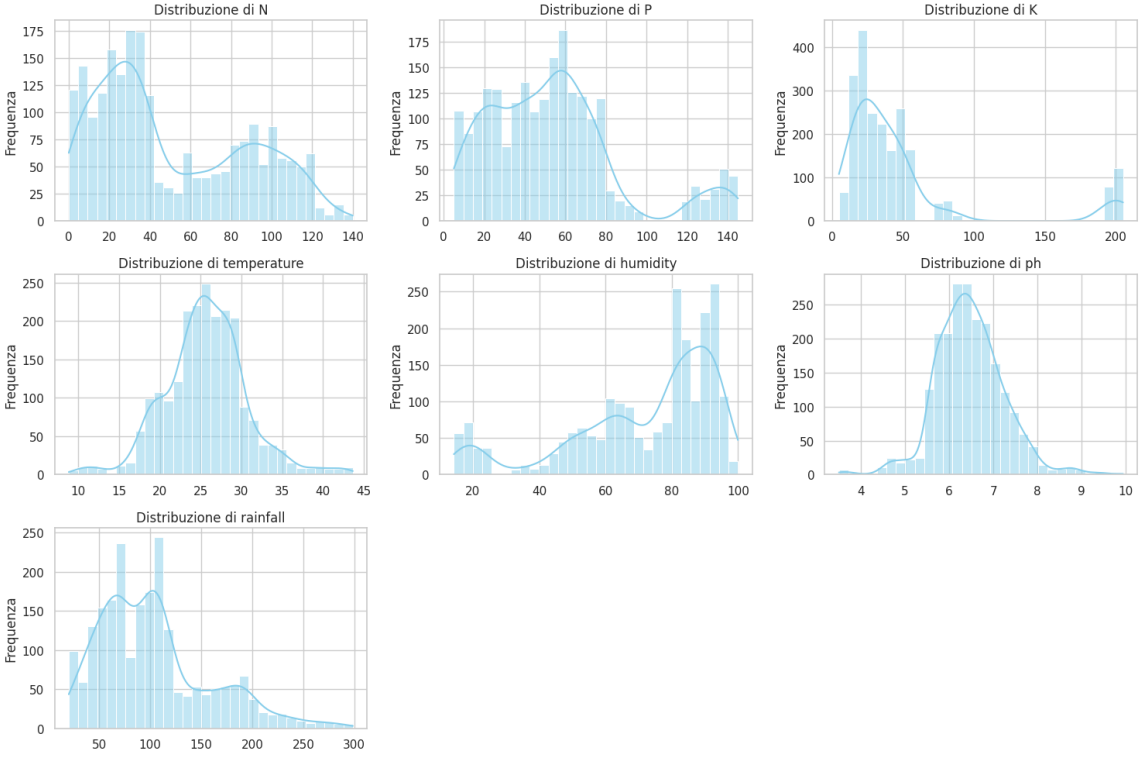


Figura 1: Distribuzione delle Feature

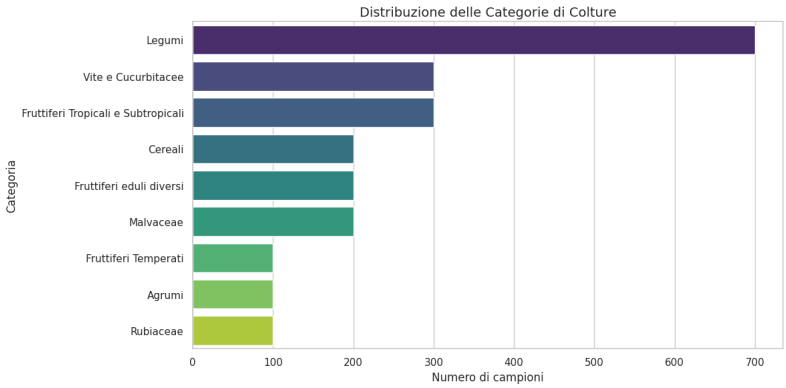


Figura 2: Distribuzione delle Categorie di colture

3 Knowledge Base in Prolog

3.1 Ruolo della Knowledge Base

Nel progetto ICON, la Knowledge Base (KB) costituisce il componente simbolico utilizzato per dedurre i patogeni potenzialmente compatibili con una determinata coltura, sulla base delle sue caratteristiche botaniche e delle condizioni climatiche e del suolo. La sua implementazione è contenuta nel file kb_agro.pl, interrogato dal notebook Python attraverso la libreria PySwip, che permette di interfacciare Python con il motore logico SWI-Prolog.

Contiene fatti e regole generali che vengono applicati ripetutamente ai dati osservati. Per ogni riga del dataset, il sistema riceve la coltura e i valori delle variabili ambientali e nutrizionali, verifica quali regole risultano soddisfatte e restituisce l'insieme dei patogeni dedotti.

L'approccio è basato su un sistema di regole deterministiche: un patogeno viene restituito quando tutte le condizioni previste dalla relativa regola finale sono soddisfatte. Il risultato rappresenta quindi un rischio compatibile con la conoscenza codificata nella KB, non una diagnosi fitopatologica accertata né una probabilità statistica di infezione.

Nel progetto, la Knowledge Base non viene utilizzata soltanto come componente di supporto, ma assume il ruolo di esperto per la generazione delle etichette del dataset. Le conoscenze di dominio, formalizzate attraverso fatti, regole e soglie definite sulla base delle informazioni agronomiche considerate, consentono di valutare ciascun campione in funzione della coltura e delle relative condizioni ambientali e del suolo. Quando la KB deduce almeno un patogeno compatibile, il campione viene classificato come a rischio (`Target_Rischio = 1`); in assenza di patogeni dedotti, viene classificato come senza rischio dedotto (`Target_Rischio = 0`).

La generazione del target a partire dalla KB costituisce quindi una scelta progettuale e rappresenta il collegamento tra ragionamento simbolico e apprendimento automatico. I classificatori supervisionati vengono addestrati per apprendere dai dati le decisioni prodotte dalla KB, con l'obiettivo di approssimare il comportamento dell'esperto anche su nuovi campioni. Il target non è pertanto un'etichetta di malattia originariamente presente nel dataset, bensì una classificazione derivata dalle conoscenze e dalle regole formalizzate nel sistema.

3.2 Rappresentazione della conoscenza in Prolog

La KB adotta una rappresentazione dichiarativa, nella quale le conoscenze sono espresse mediante fatti e regole. I fatti descrivono relazioni considerate valide, mentre le regole definiscono condizioni sufficienti per derivare nuove relazioni.

- **Fatti e conoscenza di base.** Descrive le famiglie o categorie botaniche delle colture e le associazioni dirette tra alcune colture e i patogeni. Non richiedono ulteriori verifiche: costituiscono una conoscenza esplicitamente memorizzata.

```
famiglia_pianta(chickpea, leguminosa).
famiglia_pianta(lentil, leguminosa).

categoria_pianta(papaya, fruttifero_tropicale).
categoria_pianta(mango, fruttifero_tropicale).
categoria_pianta(banana, fruttifero_tropicale).

suscettibile_brusone(X) :- famiglia_pianta(X, graminacea).
suscettibile_antracnosi_tropicale(X) :- categoria_pianta(X, fruttifero_tropicale).
```

  Il predicato famiglia_pianta viene utilizzato per la tassonomia botanica formale, raggruppando le piante in base alle loro reali famiglie scientifiche. Il predicato categoria_pianta, invece, è utilizzato per classificazioni agronomiche o commerciali: poiché botanicamente appartengono a famiglie completamente diverse, forzarle in una singola famiglia_pianta avrebbe introdotto un errore concettuale nell'ontologia.

  Le regole di suscettibilità permettono di trasferire una proprietà da una categoria botanica alle colture che ne fanno parte. Per quanto riguarda 'coconut' e 'pomegranate' non condividono ne famiglia botanica ne categoria ma hanno entrambe suscettibilità alla 'phytophthora'. Questa è quindi dichiarata direttamente come fatto atomico. Creare una categoria o una famiglia fittizia e poi scrivere una regola ad hoc solo per collegare un'unica pianta a una singola malattia avrebbe aggiunto livelli di astrazione superflui, appesantendo la base di conoscenza senza alcun reale vantaggio deduttivo. La regola stabilisce che una coltura X è considerata suscettibile a un patogeno quando esiste un fatto che la identifica in una specifica famiglia/categoria. La variabile X è una variabile

logica: non indica una coltura specifica, ma può essere associata a qualsiasi valore che soddisfi il corpo della regola. Il meccanismo evita di dover duplicare una regola di suscettibilità per ogni coltura appartenente alla medesima categoria. L'aggiunta di una nuova coltura può richiedere soltanto l'inserimento del relativo fatto botanico, purché la categoria e le regole applicabili siano già definite

- **Regole intermedie (Astrazione di Clima e Suolo).** Il secondo livello della KB descrive le condizioni climatiche favorevoli e quelle del suolo considerate vulnerabili per ciascun patogeno. La separazione tra questi due aspetti rende le regole modulari: le soglie climatiche e quelle nutrizionali possono essere aggiornate senza riscrivere necessariamente le regole di inferenza finale.

  clima_favorevole(Temp, Umidita, Pioggia, 'Brusone del Riso') :-
  $Temp \geq 25.0$,
  $Temp \leq 30.0$,
  $Umidita > 80.0$,
  $Pioggia > 100.0$.

  suolo_vulnerabile(N, P, K, PH, 'Brusone del Riso') :-
  $N \geq 70$,
  $K < 45$,
  $PH \leq 6.5$.

  Le condizioni climatiche vengono rappresentate dal predicato clima_favorevole, i cui argomenti sono temperatura, umidità, pioggia e patogeno. Perché il predicato abbia successo, tutte le condizioni devono essere soddisfatte.

  Le condizioni del suolo sono rappresentate dal predicato suolo_vulnerabile. I suoi argomenti sono azoto (N), fosforo (P), potassio (K), pH e patogeno.

- **Inferenza finale.** Il terzo livello è costituito dal predicato rischio_patogeno, che integra le conoscenze botaniche con le condizioni climatiche e quelle del suolo.

```
rischio_patogeno(Coltura, Temp, Umidita, Pioggia, N, P, K, PH, 'Brusone del Riso') :-
suscettibile_brusone(Coltura),
clima_favorevole(Temp, Umidita, Pioggia, 'Brusone del Riso'),
suolo_vulnerabile(N, P, K, PH, 'Brusone del Riso').
```

La regola contiene tre obiettivi logici in congiunzione. Prolog deve verificare che la coltura sia suscettibile al patogeno; le condizioni climatiche siano favorevoli; le condizioni del suolo siano vulnerabili. Solo se tutti e tre gli obiettivi hanno successo viene dedotto il patogeno.

Il risultato è una deduzione logica basata sulle soglie codificate, non una conferma sperimentale della presenza del patogeno.

Le colture, i patogeni e i fattori ambientali considerati nella Knowledge Base sono stati individuati sulla base di ricerche bibliografiche in ambito fitopatologico, facendo riferimento alla letteratura scientifica relativa alle malattie delle piante, ai loro ospiti e alle condizioni che ne favoriscono lo sviluppo. Le soglie numeriche implementate nelle regole rappresentano una formalizzazione operativa di tali conoscenze e devono essere considerate parametri del modello, non valori universalmente validi per ogni contesto agronomico. [2] [3] [4] [5] [6]

3.3 Applicazione delle regole al dataset

La KB viene caricata attraverso PySwip. L'elaborazione del dataset avviene attraverso un ciclo sulle righe. Per ogni campione viene effettuata una chiamata a inferisci_patogeni che estrae dalla riga del dataset la coltura e le variabili numeriche, converte i valori numerici in una rappresentazione utilizzabile da Prolog e costruisce una query. Il motore può restituire tutti i valori per i quali esiste una derivazione valida. La funzione Python converte i risultati in stringhe, elimina eventuali duplicati mediante un insieme e ordina i nomi dei patogeni. I risultati producono prima la colonna Rischio_Patogeno da cui si deduce Target_Rischio come già spiegato in precedenza.

Nelle figure 3 e 4 vengono mostrate le distribuzioni di Rischio_Patogeno e Target_Rischio.

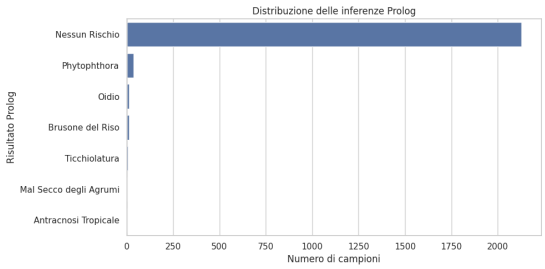


Figura 3: Distribuzione dei patogeni

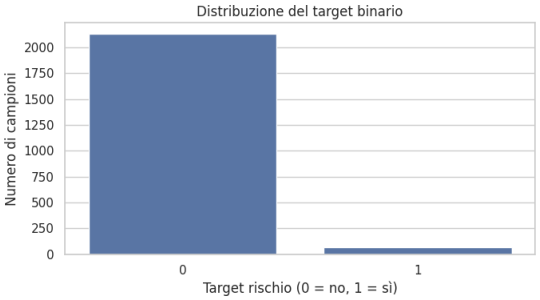


Figura 4: Distribuzione del target

3.4 Analisi strutturale quantitativa della KB

Tutti i componenti della Knowledge Base sono descritti in tabella 2. I 22 fatti comprendono 17 fatti famiglia_pianta, 3 fatti categoria_pianta e 2 fatti suscettibile_phytophthora.

Le 36 regole sono suddivise in 9 regole di suscettibilità, 18 regole intermedie (9 climatiche e 9 relative al suolo) e 9 regole finali.

I simboli di predicato distinti sono 14, considerando anche l'arità.

Componente	**Numero di clausole**
Fatti botanici e di suscettibilità diretta	22
Regole di suscettibilità derivate	9
Regole climatiche	9
Regole relative al suolo	9
Regole finali di inferenza del rischio	9
Totale fatti e regole	**58**

Tabella 2: Descrizione dei componenti della Knowledge Base.

3.5 Limiti e valutazioni conclusive

La KB offre una struttura modulare, leggibile e facilmente estendibile. La separazione tra fatti botanici, condizioni ambientali e regole finali consente di modificare le conoscenze senza dover riscrivere l'intero sistema.

In conclusione, il sistema combina una rappresentazione simbolica della conoscenza con un processo di inferenza esplicito e verificabile. Tuttavia la sua capacità predittiva resta vincolata alle colture, alle categorie e alle soglie esplicitamente rappresentate.

4 Knowledge Graph

Il Knowledge Graph è stato realizzato per integrare e rappresentare strutturalmente due livelli informativi distinti: le inferenze logiche puramente simboliche (dedotte dalla Knowledge Base in Prolog) e i dati statistico-descrittivi (derivati dai record numerici del dataset).

4.1 Rappresentazione in Triple e Classi di Nodi

La struttura del grafo si fonda sul modello relazionale basato su triple nella forma (soggetto, predicato, oggetto), in cui un soggetto è collegato a un oggetto tramite un verbo, o proprietà. Al fine di categorizzare opportunamente le entità del dominio, sono state definite tre classi principali di individui, corrispondenti a tre diverse tipologie di nodi:

- **Coltura.** Rappresenta le istanze fisiche delle varie piante presenti nel dataset (es. riso, mais, lenticchie).
- **Patogeno.** Rappresenta gli agenti patogeni e le malattie, astratti come concetti e dedotti dalle regole della KB.
- **ProfiloAmbientale.** Rappresenta le caratteristiche fisiche e chimiche dell'ambiente (es. azoto, temperatura, precipitazioni) associate quantitativamente alle piante.

L'appartenenza di un nodo a una di queste classi determina il suo ruolo semantico all'interno delle triple, definendo di fatto il dominio e il codominio delle proprietà che li collegano.

4.2 Definizione delle Relazioni

Le relazioni che intercorrono tra le classi di nodi formalizzano le connessioni logiche e quantitative dell'ecosistema agricolo studiato. Nel Knowledge Graph sono state modellate due direttrici semantiche principali (archi).
La prima è rischio_patogeno_dedotto che mappa i risultati delle inferenze del sistema Prolog, costruendo triple logiche del tipo (Coltura, rischio_patogeno_dedotto, Patogeno). Questa proprietà ha come dominio la classe delle Colture e come codominio la classe dei Patogeni. Essa costituisce un collegamento simbolico derivato dalle

regole formali del sistema esperto. L'arco rappresenta una deduzione della Knowledge Base e non costituisce, da solo, una dimostrazione empirica di causalità tra le condizioni osservate e l'insorgenza della malattia.
La seconda è ha_valore_medio che collega i dati osservati ai loro attributi quantitativi, formando triple del tipo (Coltura, ha_valore_medio, ProfiloAmbientale). In questo caso si attua una forma di reificazione: il nodo oggetto incapsula la proprietà quantitativa vera e propria (es. "temperature"), racchiudendo come attributo al suo interno il valore numerico medio calcolato sui campioni reali del dataset per quella specifica pianta. Questo approccio ibrido integra in un unico modello la conoscenza simbolica (le malattie) con i profili descrittivi, evidenziando le correlazioni senza confondere le deduzioni simboliche con la statistica descrittiva.
Gli archi tra colture e patogeni rappresentano l'esistenza di almeno un campione per il quale la KB ha dedotto il patogeno; non implicano che la stessa deduzione sia valida per tutti i campioni della coltura. I profili ambientali riportano valori medi descrittivi e non necessariamente le condizioni specifiche che hanno attivato le regole.

4.3 Rappresentazioni Grafiche e Analisi Visiva

Uno dei vantaggi principali della notazione tramite Knowledge Graph è la facilità di visualizzazione: essa consente ad agronomi e progettisti di esplorare l'organizzazione della conoscenza e le relazioni complesse senza essere costretti a conoscere o decifrare la sintassi del linguaggio logico sottostante.
Del knowledge graph sono state generate due visualizzazioni con livello di rappresentazione differente.
La prima è una visione globale (Fig. 5) che espone l'intero grafo rappresentando tutte le colture, i patogeni e i profili ambientali. L'utilizzo di specifiche codifiche visive, con nodi colorati diversamente e dimensionati in base alla loro classe di appartenenza (i patogeni, ad esempio, sono visivamente più marcati), facilita un'analisi d'insieme delle vulnerabilità trasversali alle diverse colture.
L'altra invece è una visione di una coltura specifica (Fig. 6) così da evitare il sovraccarico informativo, permettendo di estrapolare un sottografo filtrato su una singola istanza target (ad esempio, la coltura "rice") includendo solo i suoi nodi direttamente adiacenti. Questa vista circoscritta mostra le relazioni tra la coltura selezionata, i patogeni dedotti dalla KB per almeno un campione e il profilo ambientale medio calcolato sui record disponibili per quella coltura. Consente quindi di esplorare con immediatezza sia le deduzioni simboliche sia le caratteristiche ambientali descrittive,

mantenendo distinti i due livelli informativi.

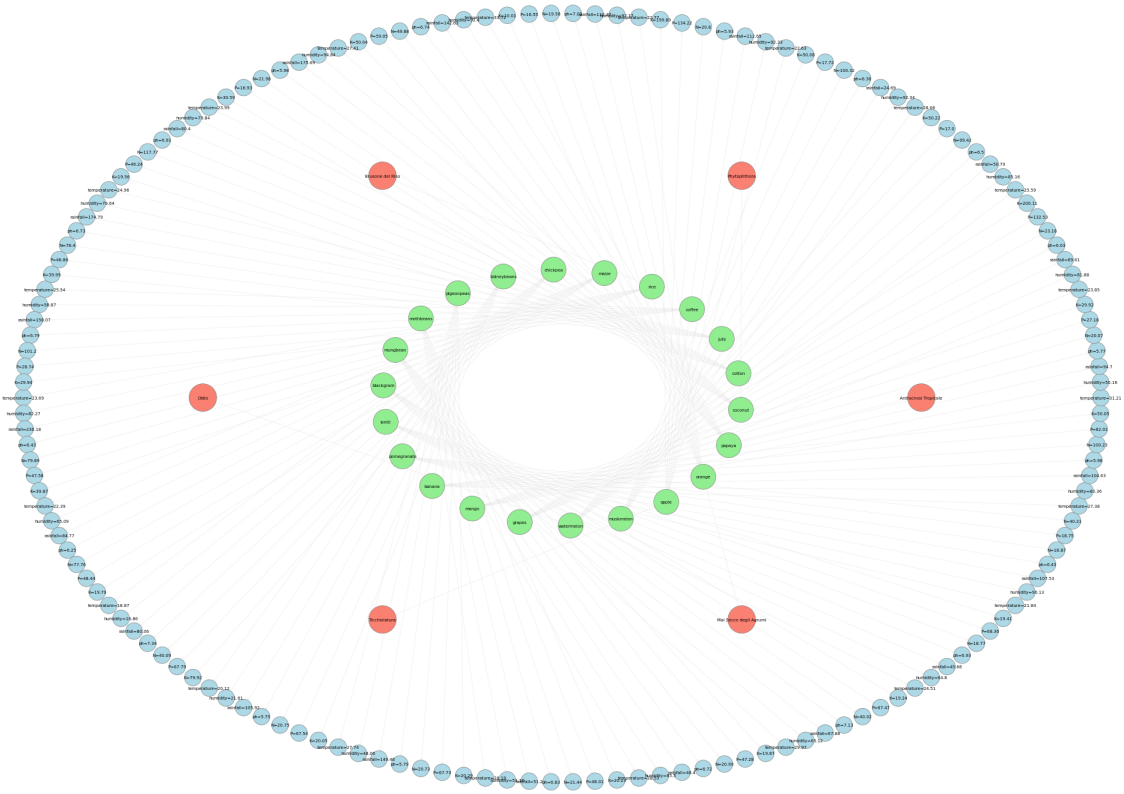


Figura 5: Knowledge Graph

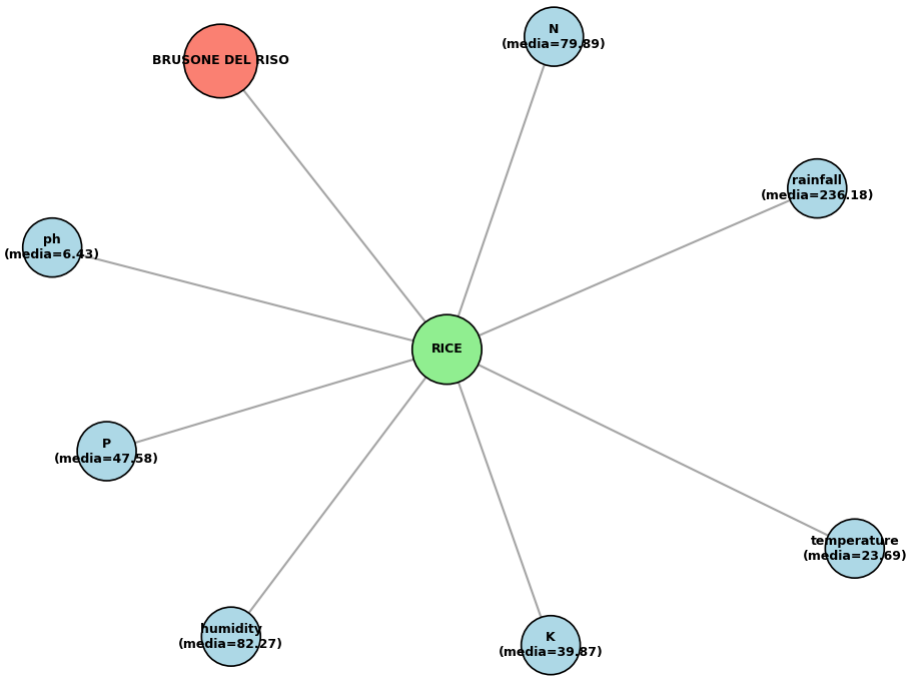


Figura 6: Knowledge Graph riso.

5 Apprendimento Supervisionato

5.1 Preprocessing

La fase di preprocessing prepara i dati per l'addestramento dei modelli e introduce una perturbazione controllata delle variabili numeriche, con l'obiettivo di simulare possibili imprecisioni nelle misurazioni ambientali.

Il target binario utilizzato nella fase di apprendimento è quello generato dalla KB secondo la procedura descritta precedentemente. In questa fase vengono definite le feature da fornire ai modelli e applicate le successive trasformazioni dei dati.

Successivamente, per colmare il divario tra i dati di laboratorio e l'applicazione nel mondo reale (dove i sensori possono registrare valori imprecisi a causa di vari fattori), è stato aggiunto un lieve rumore Gaussiano artificiale alle variabili continue. Questa scelta non rappresenta una corruzione dei dati, ma una strategia di regolarizzazione volta a forzare i modelli a non memorizzare valori esatti [7]. I valori impiegati costituiscono parametri sperimentali scelti per simulare errori di misura.

La matrice delle feature viene costruita escludendo Target_Rischio e Rischio_Patogeno, per evitare che la classificazione o il relativo output simbolico siano forniti direttamente al modello. Anche Categoria_Crop viene rimossa prima dell'addestramento.

I dati vengono suddivisi in training set e test set, rispettivamente pari all'80% e al 20% del campione, mediante una suddivisione stratificata sul target. La stessa procedura di preprocessing è implementata attraverso una pipeline: le feature numeriche sono sottoposte a imputazione mediante mediana e standardizzazione, mentre le feature categoriche sono sottoposte a imputazione mediante moda e One-Hot Encoding. L'utilizzo della pipeline permette di eseguire queste trasformazioni all'interno delle procedure di addestramento e validazione dei singoli modelli.

5.2 Modelling e Scelte Tecniche

Per la fase di apprendimento supervisionato sono stati selezionati tre classificatori:

- **Decision Tree.** è stato scelto per il suo carattere intrinsecamente interpretabile, esso permette di estrarre un set di regole logiche dalle ramificazioni create durante il training. Questo offre l'opportunità di confrontare la logica appresa

dai dati (Machine Learning) con gli assiomi inseriti manualmente dall'esperto nel modulo Prolog.

- **Random Forest.** Sebbene il singolo albero sia interpretabile, è notoriamente soggetto a un'alta varianza e al rischio di overfitting. Per confrontare un modello ensemble con il singolo albero è stata implementata una Random Forest, che aggrega le previsioni di più alberi costruiti su campioni e sottoinsiemi di feature differenti. Questo approccio consente di modellare interazioni complesse e non lineari tra i parametri ambientali, i nutrienti del suolo e il target generato dalla KB.

- **K-Nearest Neighbors.** Sfrutta direttamente la standardizzazione effettuata nel preprocessing. La sua implementazione si basa sull'assunzione secondo cui profili ambientali chimico-fisici simili (ovvero "vicini" nello spazio iperdimensionale delle feature) presentino la stessa probabilità di appartenenza alla classe di rischio.

Per ciascun classificatore è stata definita una griglia di iperparametri, esplorata mediante GridSearchCV.

Modello	**Iperparametro**	**Valori Esplorati**
Decision Tree	`max_depth`	$3, 4, 6, 8,$ None
	`min_samples_split`	$2, 5, 10$
	`criterion`	`'gini'`, `'entropy'`
Random Forest	`n_estimators`	$50, 100, 200$
	`criterion`	`'gini'`, `'entropy'`
	`max_depth`	None, $10, 15$
K-Nearest Neighbors	`n_neighbors`	$3, 5, 7, 9, 11, 15$
	`weights`	`'uniform'`, `'distance'`
	`metric`	`'euclidean'`, `'manhattan'`

Tabella 3: Griglia degli iperparametri per i classificatori.

La ricerca degli iperparametri viene effettuata utilizzando una StratifiedKFold interna a tre fold e con mescolamento dei campioni. Il criterio di selezione è l'F1-score, scelto per considerare congiuntamente precision e recall, aspetti rilevanti dato lo sbilanciamento tra le due classi.

Per il confronto dei modelli viene utilizzata una Nested Cross-Validation [8]. Il ciclo esterno è implementato mediante RepeatedStratifiedKFold, con cinque fold ripetuti tre volte, per un totale di quindici valutazioni esterne per ciascun modello. In

ogni iterazione, la ricerca interna degli iperparametri viene eseguita esclusivamente sui dati di addestramento del fold esterno; il fold esterno viene invece utilizzato per valutare il modello selezionato. Questa configurazione permette di ottenere una stima delle prestazioni che tiene conto anche della variabilità dovuta alla selezione degli iperparametri.

Le metriche considerate sono accuracy, precision, recall, F1-score e ROC-AUC. Per Decision Tree e Random Forest viene inoltre utilizzato il parametro class_weight='balanced' per compensare lo sbilanciamento delle classi durante l'addestramento. Tale opzione non è presente nel KNN implementato, che viene valutato senza questa forma di pesatura.

La scelta finale dei modelli viene quindi discussa sulla base delle prestazioni medie e della relativa deviazione standard nella validazione esterna, considerando sia la capacità di individuare la classe positiva sia la stabilità dei risultati tra le diverse partizioni.

5.3 Analisi del Processo di Addestramento

La valutazione principale dei classificatori è stata effettuata mediante Nested Cross-Validation. Per ogni modello sono state calcolate la media e la deviazione standard di accuracy, precision, recall, F1-score e ROC-AUC sulle quindici valutazioni esterne.

Modello	**Accuracy**	**Precision**	**Recall**	**F1**	**Roc-Auc**
Decision Tree	0.9494 ± 0.0316	0.3753 ± 0.0907	0.5578 ± 0.2078	0.4254 ± 0.1085	0.7620 ± 0.0978
Random Forest	0.9717 ± 0.0073	0.5910 ± 0.1997	0.3984 ± 0.1655	0.4652 ± 0.1652	0.9604 ± 0.0184
K-Nearest Neighbors	0.9715 ± 0.0060	0.5998 ± 0.1518	0.3892 ± 0.1278	0.4634 ± 0.1198	0.8369 ± 0.0707

Tabella 4: Risultati della Nested CV (media ± deviazione standard).

La media descrive le prestazioni osservate sulle diverse partizioni, mentre la deviazione standard fornisce un'indicazione della loro variabilità. Quest'ultima non deve essere interpretata come un intervallo di confidenza, ma come una misura della dispersione dei risultati ottenuti nei fold esterni.

La Random Forest ottiene il valore medio di F1-score più elevato, sebbene la differenza rispetto a KNN sia molto contenuta. Il Decision Tree raggiunge invece un F1-score medio inferiore, ma presenta il recall più alto. Questo risultato indica che l'albero decisionale riconosce mediamente una quota maggiore dei campioni positivi rispetto agli altri due classificatori, a fronte di una precision più bassa.

La Random Forest presenta inoltre il ROC-AUC più elevato, nettamente superiore a quello degli altri due modelli. Il risultato suggerisce una migliore capacità discriminativa complessiva della Random Forest rispetto ai punteggi degli altri modelli.

Per quanto riguarda l'accuracy, Random Forest e KNN, mostrano prestazioni medie quasi identiche. Questo indicatore deve essere interpretato con cautela, poiché il target è fortemente sbilanciato a favore della classe negativa. Un classificatore che assegnasse sempre la classe negativa potrebbe infatti ottenere un'accuracy elevata senza individuare alcun campione positivo.

Anche la variabilità dei risultati fornisce informazioni utili. La deviazione standard del recall del Decision Tree è particolarmente elevata, indicando una notevole dipendenza dalle partizioni utilizzate. Random Forest presenta un ROC-AUC più stabile, mentre la deviazione standard dell'F1-score rimane significativa per entrambi i modelli ad albero e per KNN. Le differenze osservate suggeriscono quindi di non individuare un unico classificatore migliore sulla base di una sola metrica.

Nel complesso, la Random Forest offre il compromesso più favorevole in termini di F1-score medio e ROC-AUC, mentre il Decision Tree privilegia maggiormente il riconoscimento della classe positiva. KNN ottiene un F1-score molto vicino a quello della Random Forest, ma un ROC-AUC inferiore. La scelta del modello dipende pertanto dalla priorità assegnata alla capacità discriminativa complessiva oppure al riconoscimento dei campioni a rischio.

È importante ricordare che queste prestazioni misurano la capacità di prevedere il target derivato dalla Knowledge Base, non la capacità di identificare patologie confermate da osservazioni indipendenti.

5.4 Analisi sul Test Set e Curve di Apprendimento

A integrazione della validazione incrociata, è stata eseguita una valutazione su un test set ottenuto mediante una suddivisione stratificata dei dati, con il 20% dei campioni riservato alla valutazione finale. Per ciascun classificatore, la ricerca degli iperparametri è stata effettuata sul solo training set e il modello selezionato è stato successivamente valutato sul test set.

I risultati della Nested Cross-Validation riportati nella sezione precedente e quelli ottenuti sul test set descrivono due valutazioni differenti. I primi sintetizzano le prestazioni medie sulle partizioni esterne del training set, mentre i secondi riguar-

dano una singola partizione riservata alla valutazione finale. I valori non devono quindi coincidere necessariamente e vanno interpretati tenendo conto della diversa procedura di valutazione.

Per ciascun modello vengono riportati i parametri selezionati e i valori di accuracy, precision, recall, F1-score e ROC-AUC. Questa valutazione fornisce un riscontro aggiuntivo su una specifica partizione dei dati.

Modello	**Migliori Parametri**	**Classe / Metrica**	**Precision**	**Recall**	**F1-score**	**Support**

Decision Tree	`criterion = 'gini'`
	`max_depth = None`
	`min_samples_split = 10`
		Nessun rischio dedotto	0.99	0.98	0.98	426

		Rischio dedotto	0.47	0.64	0.55	14
		Accuracy	–	–	0.97	440
		Macro avg	0.73	0.81	0.76	440
		Weighted avg	0.97	0.97	0.97	440

Random Forest	`criterion = 'gini'`
	`max_depth = 10`
	`n_estimators = 50`
		Nessun rischio dedotto	0.98	0.99	0.99	426

		Rischio dedotto	0.60	0.43	0.50	14
		Accuracy	–	–	0.97	440
		Macro avg	0.79	0.71	0.74	440
		Weighted avg	0.97	0.97	0.97	440

K-Nearest Neighbors	`metric = 'manhattan'`
	`n_neighbors = 3`
	`weights = 'uniform'`
		Nessun rischio dedotto	0.98	1.00	0.99	426

		Rischio dedotto	0.86	0.43	0.57	14
		Accuracy	–	–	0.98	440
		Macro avg	0.92	0.71	0.78	440
		Weighted avg	0.98	0.98	0.98	440

Tabella 5: Tabella riassuntiva integrata con i parametri ottimali e i report di classificazione.

Sono state inoltre esaminate le curve di apprendimento, calcolate utilizzando cinque diverse dimensioni del training set e una validazione incrociata stratificata a cinque fold. La metrica considerata è l'F1-score. Le curve permettono di osservare come variano le prestazioni di addestramento e di validazione al crescere del numero di campioni utilizzati.

Decision Tree. La curva di training presenta un andamento oscillante, mantenendosi complessivamente su valori relativamente elevati. La curva di validazione mostra invece un andamento irregolare, ma con una tendenza complessivamente crescente verso le dimensioni maggiori del training set. Il divario tra le due curve suggerisce una difficoltà di generalizzazione: il modello si adatta ai dati di addestramento con maggiore efficacia rispetto ai campioni di validazione. L'incremento finale delle prestazioni di validazione indica tuttavia che una maggiore disponibilità di campioni può essere utile, sebbene il miglioramento non sia costante.

Random Forest. Il punteggio di training rimane prossimo a 1 per quasi tutte

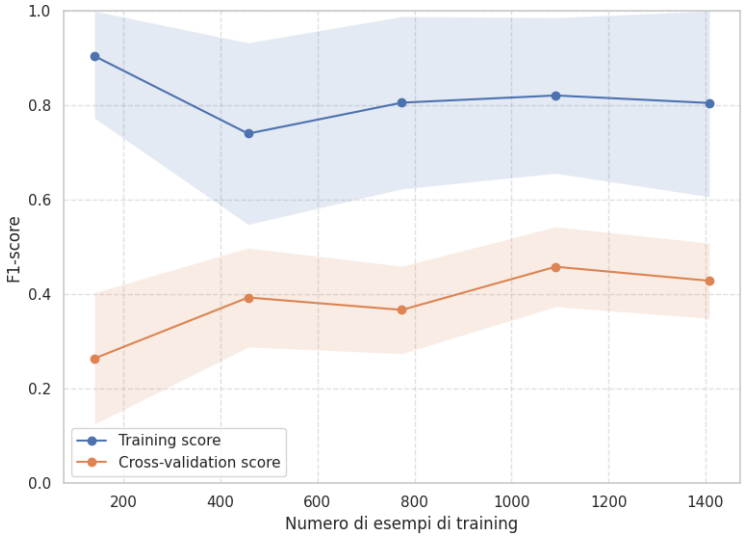


Figura 7: Curva di apprendimento - Decision Tree

le dimensioni considerate, mentre l'F1-score di validazione è sensibilmente inferiore. Quest'ultimo mostra un miglioramento complessivo al crescere del numero di campioni, stabilizzandosi nelle dimensioni maggiori intorno a valori di 0,4–0,45. Il divario persistente tra le curve è indicativo di un possibile overfitting: il modello si adatta molto bene ai dati utilizzati per l'addestramento, ma non raggiunge prestazioni altrettanto elevate sui campioni di validazione. L'aggiunta di dati sembra favorire la validazione, senza tuttavia eliminare la differenza tra le due curve.

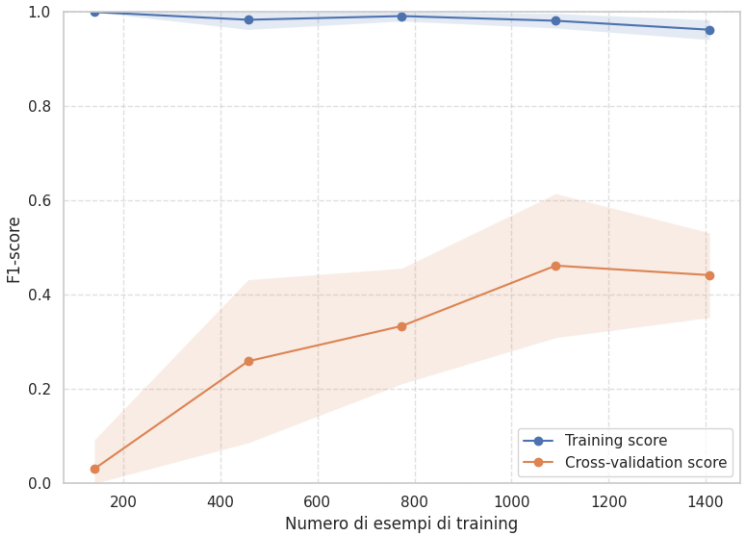


Figura 8: Curva di apprendimento - Random Forest

K-Nearest Neighbors. La curva di training mostra inizialmente un incremento, seguito da una progressiva stabilizzazione, con alcune oscillazioni nelle dimensioni intermedie. La curva di validazione presenta invece una tendenza complessivamente

crescente, raggiungendo valori prossimi a 0,45 nella dimensione massima del training set. Questo andamento suggerisce che l'aumento dei campioni possa favorire la capacità del modello di generalizzare a dati non utilizzati per l'addestramento. Permane tuttavia una differenza tra le due curve, che indica prestazioni di validazione inferiori a quelle ottenute sul training set. Rispetto agli altri classificatori, KNN mostra un divario finale più contenuto, pur senza raggiungere prestazioni di validazione pienamente soddisfacenti.

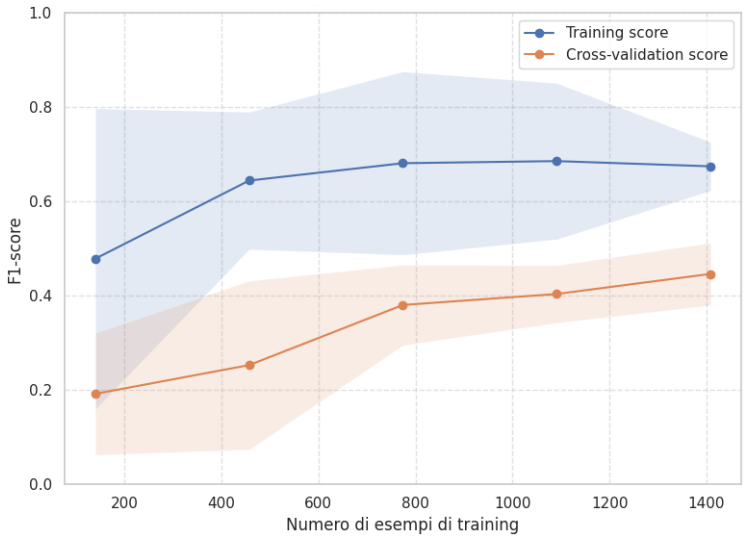


Figura 9: Curva di apprendimento - KNN

La scarsa rappresentazione della classe positiva rende più difficile ottenere stime stabili dell'F1-score quando il numero di campioni disponibili è ridotto.

Nel complesso, le curve evidenziano una differenza tra le prestazioni sul training set e quelle in validazione per tutti e tre i classificatori, sebbene con caratteristiche differenti. In generale, l'aumento dei campioni sembra favorire le prestazioni di validazione, anche se il miglioramento non è sempre costante e non elimina le difficoltà di generalizzazione. Questi risultati devono essere interpretati considerando la limitata presenza della classe positiva e confrontati con quelli della Nested Cross-Validation e della valutazione sul test set.

5.5 Analisi degli Errori

Per approfondire il comportamento dei classificatori e la distribuzione dei loro errori, sono state costruite matrici di confusione aggregate mediante una cross-validation stratificata a cinque fold sul training set. Per ciascun modello, le predizioni ottenute sui fold di validazione vengono riunite in un'unica matrice, che riassume

i conteggi complessivi di veri negativi, falsi positivi, falsi negativi e veri positivi sui campioni del training set.

Questa analisi è distinta dalla valutazione sul test set, riservata al confronto delle metriche di classificazione riportate nella sezione precedente. L'impiego di predizioni aggregate consente di esaminare gli errori su più partizioni dei dati, anziché basare l'analisi delle matrici di confusione esclusivamente su una singola valutazione. Gli errori sono riferiti al target binario derivato dalla Knowledge Base e non rappresentano necessariamente errori nell'identificazione di patologie effettivamente presenti nelle colture.

In un contesto di prevenzione fitopatologica, i falsi negativi meritano particolare attenzione, poiché rappresentano campioni per i quali il sistema non segnala un rischio dedotto dalla KB. I falsi positivi, invece, identificano campioni per i quali il modello segnala un rischio che non appartiene alla classe positiva del target utilizzato.

Il Decision Tree (Fig. 10) tra i tre classificatori, individua il maggior numero di campioni positivi. Il recall della classe positiva è il più elevato tra i modelli considerati. Questo risultato evidenzia una maggiore capacità di riconoscere i campioni per i quali la Knowledge Base ha dedotto una condizione di rischio. Tale comportamento è accompagnato, tuttavia, dal numero più alto di falsi positivi, che indica una maggiore tendenza a segnalare erroneamente come a rischio campioni appartenenti alla classe negativa.

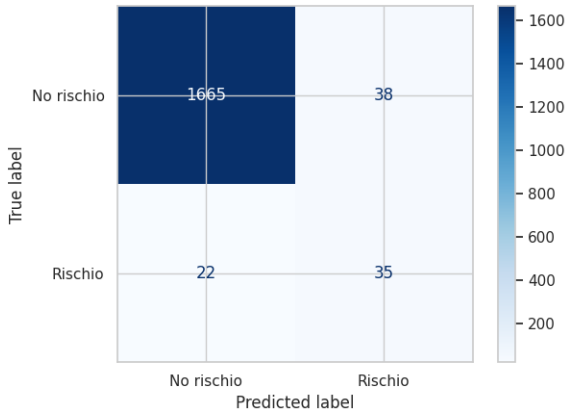


Figura 10: Matrice di confusione aggregata - Decision Tree

La matrice della Random Forest (Fig. 11) indica che il modello produce il minor numero di falsi positivi tra i tre classificatori, mostrando una buona capacità di riconoscere i campioni appartenenti alla classe negativa. Questa caratteristica è però accompagnata da una minore capacità di individuare i campioni positivi, con il

recall più basso tra i modelli analizzati. La Random Forest privilegia maggiormente il contenimento dei falsi allarmi, a costo di non riconoscere una quota considerevole dei campioni a rischio secondo la Knowledge Base.

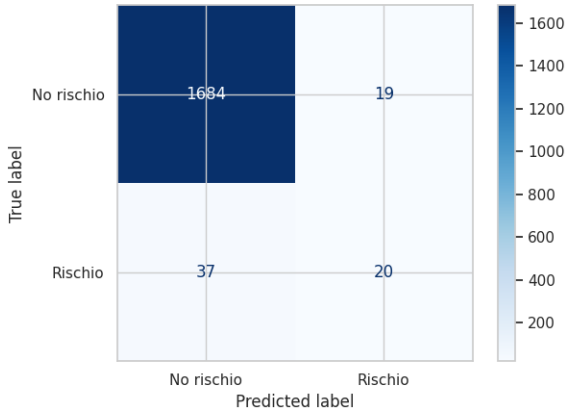


Figura 11: Matrice di confusione aggregata - Random Forest

KNN (Fig. 12) risulta intermedio rispetto a Decision Tree e Random Forest. Ottiene un recall superiore a quello della Random Forest ma inferiore a quello del Decision Tree. Il numero di falsi positivi è inferiore a quello del Decision Tree e lievemente superiore a quello della Random Forest. La precision sulla classe positiva è il valore più alto tra i tre classificatori. Il KNN presenta quindi un compromesso intermedio tra la capacità di individuare i campioni positivi e il contenimento delle segnalazioni errate.

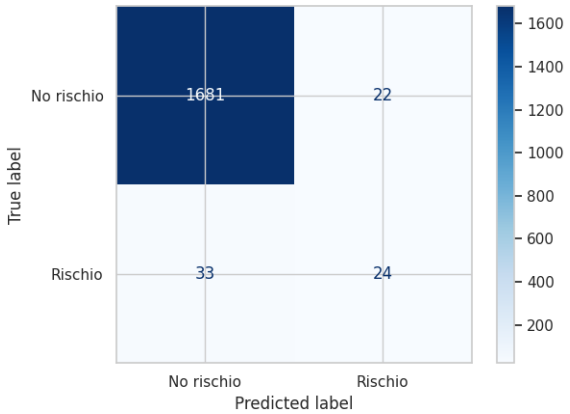


Figura 12: Matrice di confusione aggregata - KNN

Questi errori devono essere interpretati rispetto al target generato da Prolog: un falso negativo è un campione per il quale il modello non riproduce una deduzione positiva della KB, non necessariamente un caso reale di malattia non riconosciuta. Analogamente, un falso positivo non dimostra che il sistema abbia segnalato una patologia assente nella realtà.

6 Prototipo di utilizzo

La funzione valuta_nuovo_campione rappresenta il punto di ingresso del prototipo in fase di utilizzo. Riceve il nome della coltura e i valori di azoto, fosforo, potassio, temperatura, umidità, pH e precipitazioni. Il modello selezionato restituisce una previsione binaria e uno score ottenuto tramite predict_proba. Parallelamente, la funzione interroga la Knowledge Base Prolog per ottenere gli eventuali patogeni compatibili con le condizioni fornite.

La presenza di due risultati distinti consente di evidenziare eventuali discrepanze. Ad esempio, quando il modello segnala un rischio ma Prolog non deduce alcun patogeno, la funzione produce un messaggio di attenzione. Questa situazione non dimostra automaticamente che una delle due componenti sia errata: può riflettere differenze tra la classificazione appresa e le condizioni esplicite delle regole, oppure una copertura incompleta della KB.

La fase di deployment mostra quindi come le componenti simbolica e numerica possano essere utilizzate in parallelo. Il prototipo fornisce una classificazione appresa e, separatamente, i patogeni dedotti dal ragionamento simbolico. La probabilità restituita dal classificatore deve essere interpretata come uno score del modello rispetto al target utilizzato per l'addestramento, non come una probabilità calibrata dell'effettiva insorgenza di una malattia.

7 Conclusioni

Il progetto ha portato alla realizzazione di un prototipo di Knowledge-Based System per la valutazione del rischio fitopatologico, basato sull'integrazione di una Knowledge Base in Prolog, un Knowledge Graph e tre modelli di classificazione supervisionata. La componente simbolica permette di dedurre i patogeni compatibili con una determinata coltura e con specifiche condizioni ambientali, mentre il Knowledge Graph rappresenta le relazioni tra colture, patogeni e profili ambientali. I classificatori supervisionati sono stati invece utilizzati per apprendere a prevedere la classificazione binaria generata dalla KB a partire dai dati in ingresso, perturbati per simulare possibili imprecisioni nelle misurazioni.

La valutazione mediante Nested Cross-Validation ha evidenziato differenze tra i modelli in funzione delle metriche considerate. I risultati ottenuti indicano che non esiste un modello migliore rispetto a tutti i criteri considerati e che la scelta dipende dal compromesso tra capacità discriminativa, individuazione dei campioni positivi e stabilità delle prestazioni.

La valutazione sul test set ha confermato la necessità di considerare congiuntamente le diverse metriche. Il confronto evidenzia comportamenti differenti: il Decision Tree privilegia il riconoscimento della classe positiva, mentre KNN produce meno segnalazioni positive errate. L'accuracy elevata osservata per tutti i modelli deve essere interpretata alla luce dello sbilanciamento del test set, nel quale i campioni positivi rappresentano soltanto 14 osservazioni su 440.

L'analisi degli errori è stata ulteriormente approfondita mediante matrici di confusione aggregate tramite cross-validation stratificata a cinque fold sul training set. I risultati confermano differenze nel comportamento dei classificatori: il Decision Tree individua il maggior numero di campioni positivi, ma presenta anche il numero più elevato di falsi positivi. La Random Forest limita maggiormente le segnalazioni errate, ma presenta il numero più alto di falsi negativi. KNN mostra un comportamento intermedio. Nel complesso, questi risultati evidenziano che una maggiore capacità di individuare i campioni a rischio può comportare un incremento delle segnalazioni errate, mentre una maggiore prudenza nella classificazione può determinare la mancata individuazione di una parte dei campioni positivi. Le matrici aggregate integrano quindi la valutazione sul test set, offrendo un ulteriore punto di vista sulla distribuzione degli errori nelle diverse partizioni dei dati.

Le curve di apprendimento hanno evidenziato difficoltà di generalizzazione per tutti e tre i classificatori, con differenze nel comportamento osservato. I risultati sug-

geriscono che una maggiore disponibilità di dati possa favorire la generalizzazione, senza garantire un miglioramento costante né prestazioni pienamente soddisfacenti. La limitata presenza della classe positiva contribuisce inoltre alla variabilità delle stime e rende necessario interpretare le curve congiuntamente ai risultati della Nested Cross-Validation e della valutazione sul test set.

Nel complesso, il progetto costituisce una base per lo studio di un sistema che affianca ragionamento simbolico e apprendimento automatico in ambito agricolo. I risultati ottenuti mostrano l'utilità di confrontare più modelli e più metriche, ma evidenziano anche che la valutazione delle prestazioni deve essere accompagnata da un'attenta analisi del target e dei limiti dei dati utilizzati. La validazione su osservazioni indipendenti rimane il passaggio fondamentale per stabilire se il prototipo possa essere impiegato efficacemente come strumento di supporto alle decisioni agronomiche.

Riferimenti bibliografici

[1] A. Ingle, "Crop Recommendation Dataset," 2020. Dataset disponibile su Kaggle.

[2] R. Oliver, *Agrios' plant pathology*. Elsevier, 2024.

[3] A. C. Kushalappa and A. B. Eskes, *Coffee rust: epidemiology, resistance, and management*. CRC Press, 1989.

[4] A. Stensvand, D. M. Gadoury, T. Amundsen, L. Semb, and R. C. Seem, "Ascospore release and infection of apple leaves by conidia and ascospores of venturia inaequalis at low temperatures," *Phytopathology*, vol. 87, no. 10, pp. 1046–1053, 1997.

[5] Q. Migheli, S. O. Cacciola, V. Balmas, A. Pane, D. Ezra, and G. M. di San Lio, "Mal secco disease caused by phoma tracheiphila: a potential threat to lemon production worldwide," *Plant Disease*, vol. 93, no. 9, pp. 852–867, 2009.

[6] S. Bautista-Baños, *Postharvest decay: Control strategies*. Elsevier, 2014.

[7] C. M. Bishop, "Training with noise is equivalent to tikhonov regularization," *Neural computation*, vol. 7, no. 1, pp. 108–116, 1995.

[8] D. Berrar, "Cross-Validation," in *Encyclopedia of Bioinformatics and Computational Biology*, vol. 1, pp. 542–545, Elsevier, 2019.